

Plan de modèle prédictif — Délinquance Geldium

Ce plan décrit l'approche de modélisation proposée pour prévoir quels clients de Geldium présentent le plus grand risque de défaut de paiement. Il s'appuie sur les enseignements de l'analyse exploratoire (partie 1) et sur des outils GenAI utilisés pour structurer la logique du modèle, sa justification et son évaluation.

1. Logique du modèle (générée avec la GenAI)

Le modèle estime, pour chaque client, la probabilité qu'il devienne délinquant. Cette probabilité est convertie en bande de risque (Faible / Moyen / Élevé) qui déclenche une action d'intervention graduée. La logique ci-dessous a été générée avec la GenAI à partir des prompts suivants, puis ajustée selon les résultats de l'EDA :

- « Esquisse un pipeline de modélisation prédictive pour prévoir les retards de crédit, de la sélection des variables à l'évaluation. »
- « Propose deux options de modélisation (simple et complexe) pour prédire la délinquance, et recommande-en une. »
- « Explique comment le modèle transforme les variables d'un client en une prédiction finale du risque. »
- « Génère un pseudocode pour un modèle de risque de crédit utilisant le revenu, l'utilisation du crédit et les paiements manqués. »

Deux options de modélisation comparées :

	Option simple : régression logistique	Option complexe : gradient boosting (XGBoost / LightGBM)
Principe	Combinaison linéaire pondérée des variables, transformée en probabilité (sigmoïde)	Certaines d'arbres de décision construits séquentiellement, chacun corrigeant les erreurs du précédent
Interprétabilité	Élevée : chaque coefficient se lit comme un effet sur le risque	Faible en natif, nécessite SHAP
Non-linéarités	À créer manuellement	Capturées automatiquement
Données requises	Fonctionne avec 500 lignes	Risque élevé de surapprentissage sur 500 lignes
Usage dans le secteur	Standard des scorecards de crédit réglementées	Modèle challenger, détection de fraude

Recommandation : la régression logistique pondérée comme modèle principal, avec le gradient boosting comme challenger pour vérifier qu'aucune relation non linéaire importante n'est ignorée.

Flux de travail du modèle (sortie GenAI
paraphrasée)

1. Ingestion et validation : contrôle du schéma, des plages (utilisation 0–1,2 ; score 300–850) et de la cohérence âge/ancienneté.

2. Nettoyage : normalisation d'Employment_Status, imputation médiane + indicateurs de valeur manquante (cf. EDA).
3. Ingénierie des variables : Missed_6m, Late_6m, Recent_Missed (Month_6), Over_Limit, New_Account (ancienneté = 0).
4. Prétraitement : standardisation des numériques, encodage one-hot des catégorielles ; Location et Age exclus (équité).
5. Modèle : régression logistique pondérée (class_weight = « balanced », 16 % de délinquants).
6. Sortie : probabilité de défaut → bande de risque par rang (Élevé = top 10 %, Moyen = 10–30 %) → action (aucune / rappel automatique / contact par un conseiller).

Pseudocode :

```
CHARGER données clients ; VALIDER schéma et plages
NETTOYER : normaliser Employment_Status ; imputer Income, Loan_Balance, Credit_Score
CRÉER : Missed_6m, Late_6m, Recent_Missed, Over_Limit, New_Account
X ← historique de paiement, Credit_Utilization, Debt_to_Income_Ratio, Credit_Score,
Employment_Status, ...
y ← Delinquent_Account
DIVISER entraînement 80 % / test 20 % (stratifié sur y)
PIPELINE ← Standardisation + OneHot + RégressionLogistique(poids équilibrés)
ENTRAÎNER avec validation croisée 5 plis ; CALIBRER les probabilités
POUR chaque client :
    p ← probabilité de défaut
    bande ← Élevé (top 10 %) | Moyen (10–30 %) | Faible
    EXPLIQUER : 3 variables qui contribuent le plus (coefficient × valeur)
RETOURNER p, bande, explication
```

Synthèse du modèle choisi :

Une régression logistique pondérée estime la probabilité de délinquance de chaque client à partir d'une combinaison linéaire de ses caractéristiques financières et de son historique de paiement. Cette probabilité est convertie en bande de risque qui déclenche une intervention graduée, et chaque prédiction s'explique par les coefficients du modèle. Un gradient boosting sert de challenger pour détecter d'éventuelles relations non linéaires.

Les 5 principales variables d'entrée :

#	Variable	Contribution attendue à la prédiction
1	Historique de paiement (Missed_Payments, Missed_6m, Recent_Missed)	Premier prédicteur du risque de crédit : les retards passés et récents annoncent les défauts futurs. À fiabiliser (incohérence relevée dans l'EDA).
2	Credit_Utilization (+ Over_Limit)	Une utilisation élevée ou un dépassement de limite signale une tension de trésorerie.
3	Debt_to_Income_Ratio	Mesure la capacité de remboursement : plus le ratio est élevé, moins le client a de marge.
4	Credit_Score	Synthèse externe de la solvabilité, standard dans les modèles de crédit.
5	Employment_Status	La stabilité des revenus influence la capacité à payer (19,4 % de délinquance chez les chômeurs).

Variables secondaires : Account_Tenure / New_Account (28,6 % de délinquance pour les comptes de moins d'un an), Credit_Card_Type, Income, Loan_Balance.

Variables exclues : Location et Age, pour éviter une discrimination géographique ou liée à l'âge. Elles sont réservées aux contrôles d'équité.

Point d'attention : appliqué au jeu actuel, le pipeline reproduit les relations inversées constatées dans l'EDA (des clients avec 6 paiements manqués classés « Faible »). La logique est valable, mais le modèle ne doit pas être déployé avant la fiabilisation des données par Geldium.

2. Justification du choix du modèle

Pourquoi ce type de modèle ? Critères considérés : précision, transparence, facilité de mise en œuvre, pertinence pour la prédiction financière et adéquation aux besoins de Geldium.

Prompts GenAI utilisés :

- « Explique les avantages et inconvénients de la régression logistique par rapport aux arbres de décision pour la prévision du risque financier. »

- « Compare les options de modèles pour prédire la délinquance et explique comment elles équilibrent performance et explicabilité. »

- « Explique comment ces modèles répondent aux besoins opérationnels : vitesse, scalabilité et facilité de surveillance. »

Comparaison des options :

Critère	Régression logistique	Arbre de décision	Gradient boosting
Précision attendue	Bonne si les relations sont monotones (cas typique du crédit)	Moyenne, scores en paliers	Souvent la meilleure sur de grands volumes
Interprétabilité	Odds ratios lisibles, codes motifs par client	Règles « si... alors » lisibles si l'arbre est peu profond	Boîte noire, nécessite SHAP
Conformité réglementaire	Standard accepté des régulateurs (scorecards)	Acceptable	Documentation et validation renforcées
Données financières (500 lignes, 16 % de défauts)	Stable, déséquilibre géré par pondération	Surapprentissage sans élagage	Surapprentissage élevé
Vitesse / scalabilité	Millisecondes ; formule déployable même en SQL	Rapide	Entraînement et réglage plus coûteux
Surveillance	Suivi simple de la dérive de chaque coefficient	Simple	Dérive diffuse sur des centaines d'arbres

Justification :

La régression logistique pondérée est le modèle le plus adapté aux besoins actuels de Geldium. Dans le crédit à la consommation, chaque décision défavorable doit pouvoir être expliquée au client et au régulateur (Equal Credit Opportunity Act aux États-Unis, article 22 du RGPD en Europe). Les coefficients de la régression logistique se traduisent directement en odds ratios et en codes motifs (« utilisation élevée du crédit », « paiements manqués récents »), ce qui répond

à cette exigence de transparence sans outil supplémentaire. Le modèle est aussi adapté aux données : il reste stable sur 500 clients et gère le déséquilibre des classes (16 % de délinquants) par simple pondération, alors qu'un gradient boosting surapprendrait et qu'un arbre de décision produirait des scores en paliers. Sur le plan opérationnel, il s'entraîne et score en quelques millisecondes, se déploie comme une simple formule (y compris en SQL dans les systèmes existants) et se surveille facilement en suivant la dérive de chaque coefficient. Le compromis est une précision potentiellement inférieure si des relations non linéaires fortes existent. C'est pourquoi un gradient boosting sera entraîné comme challenger : s'il dépasse nettement la régression logistique en AUC, les interactions qu'il détecte seront ajoutées explicitement au modèle principal.

Ce que la transparence a permis de détecter : appliquée aux données actuelles, la régression logistique affiche des coefficients de signe contraire à la logique métier : les paiements manqués réduisent le risque estimé, tandis que le Credit_Score et le revenu l'augmentent. Un modèle boîte noire aurait masqué ces incohérences ; la régression logistique les rend visibles immédiatement, ce qui confirme les problèmes de données de l'EDA et illustre pourquoi un modèle contrôlable par des experts métier est indispensable en contexte financier.

3. Stratégie d'évaluation

Comment évaluer la performance du modèle : métriques utilisées et interprétation, détection et réduction des biais, considérations éthiques liées aux prédictions sur le comportement financier des clients.

Prompts GenAI utilisés :

- « Suggère un ensemble de métriques pour évaluer un modèle de prédiction du risque financier en termes de précision, d'équité et de biais. »
- « Donne des exemples de techniques de réduction des biais en modélisation du risque de crédit. »
- « Comment interpréter ces métriques et décider quand un modèle doit être amélioré avant déploiement ? »

Protocole : validation croisée stratifiée en 5 plis sur les 500 clients ; signalement du top 30 % de risque (bandes Moyen + Élevé) ; comparaison avec le challenger gradient boosting et un modèle naïf ; audit d'équité par tranche d'âge et par ville.

Métriques, interprétation et seuils d'acceptation :

Métrique	Ce qu'elle mesure / interprétation	Seuil
AUC-ROC	Capacité à classer un délinquant au-dessus d'un non-délinquant (0,5 = hasard)	$\geq 0,70$
Rappel	Part des vrais délinquants repérés ; manquer un défaut coûte cher à Geldium	$\geq 0,60$
Précision	Part des clients signalés réellement délinquants ; évite de solliciter les bons clients	$\geq 0,32$ ($2 \times$ taux de base)
Score F1	Équilibre précision / rappel, adapté au déséquilibre des classes	À maximiser
Score de Brier	Fiabilité des probabilités annoncées (calibration)	$< 0,134$ (modèle

		naïf)
Impact disparate	Taux de signalement du groupe le moins signalé + celui du plus signalé	$\geq 0,80$ (règle des 4/5)
Égalité des chances	Écart de rappel entre groupes : les délinquants de chaque groupe sont détectés de la même façon	$\leq 0,10$

Accuracy : elle est écartée, car un modèle qui prédit « jamais délinquant » atteint 84 % d'accuracy sans aucune utilité.

Règle de décision : si l'AUC ou le rappel n'atteint pas son seuil, le modèle n'est pas déployé : on retourne à l'étape données / variables. Si une métrique d'équité déclenche une alerte, on applique une technique de réduction des biais puis on relance l'audit.

Détection et réduction des biais :

- **Avant l'entraînement** : exclure les attributs sensibles (Age, Location) et vérifier les proxys (par exemple la carte Student, liée à l'âge) ; repondérer les groupes sous-représentés.

- **Pendant l'entraînement** : contrainte d'équité (par exemple fairlearn ExponentiatedGradient avec parité démographique ou égalité des chances).

- **Après l'entraînement** : ajustement des seuils de signalement par groupe (ThresholdOptimizer) si un groupe reste défavorisé.

- **En production** : audit d'équité mensuel et suivi de la dérive des données (indice PSI > 0,2 $\Rightarrow$ réentraînement).

Considérations éthiques :

- Le score sert à proposer de l'aide (rappel, plan de paiement), jamais à sanctionner automatiquement : toute décision défavorable est validée par un conseiller.

- Chaque client signalé dispose de codes motifs explicables et d'un droit de contestation.

- Les clients vulnérables (chômeurs, nouveaux comptes) font l'objet d'une attention particulière pour éviter une exclusion systématique du crédit.

- Les données personnelles sont minimisées et protégées : accès restreint, aucune variable sans lien avec la solvabilité.

Application du protocole au jeu de données actuel :

Modèle	AUC	Rappel	Précision	F1	Brier
Régression logistique	0,49	0,29	0,15	0,20	0,25
Gradient boosting (challenger)	0,37	0,16	0,09	0,11	0,23
Modèle naïf	0,50	0,24	0,13	0,17	0,13

Interprétation : aucune métrique n'atteint son seuil, et les deux modèles ne font pas mieux que le hasard. La règle de décision conclut donc « non déployable », ce qui est cohérent avec l'EDA. Côté équité, l'impact disparate passe le seuil (0,84 par âge, 0,80 par ville), mais l'écart de rappel déclenche une alerte (0,16 entre tranches d'âge, 0,11 entre villes). Avec seulement 11 à 37 délinquants par groupe, ces écarts sont peu fiables. Le cadre d'évaluation fonctionne comme

prévu : il bloque un modèle qui n'apprend rien d'utile avant qu'il n'atteigne les clients. Une fois les données corrigées par Geldium, le même protocole sera relancé tel quel.

4. Conclusion

La régression logistique pondérée reste le bon choix pour Geldium : elle est transparente, conforme aux exigences réglementaires et simple à déployer et à surveiller. Le protocole d'évaluation montre toutefois qu'avec les données actuelles, aucun modèle ne fait mieux que le hasard ($AUC \approx 0,49$). La priorité est donc de corriger les données avec Geldium (historique de paiement incohérent, profils impossibles), puis de relancer ce même pipeline et ce même protocole avant tout déploiement.